Procesarea Imaginilor Asistată de AI pentru Diminuarea Falselor Pozitive în Sistemele de Supraveghere Video

Implicații asupra Rezilienței Operaționale în Securitatea Cibernetică

Ioana

DE UNDE A PORNIT

Lucrez part-time în echipa de audit 24/7 BigBrother International. Unul din task-uri e de a tria alertele primite de la camerele de supraveghere montate pe locațile clienților. Odată primită alerta, eu iau decizia dacă este o alertă reala sau una falsă, încerc să identific cauza pornirii alarmei și să propun îmbunatățiri pentru sistemul de detecție. Unii din clienți plătesc și supravegherea constantă a locațiilor, iar în caz de evenimente precum furt sau vandalism, trebuie să escalăm problema și să contactăm autoritățiile în unele cazuri.

Sistemul în prezent nu distinge între o alertă reală și una falsă, doar semnalează mișcarea în zona marcată, indiferent de cauză. Tocmai din acest motiv, dacă oameni doar trec pe langă zona marcată sau frunze și insecte apar în cadrul camerei, o alertă este declanșată. Acest lucru face ca sistemul să ofere alerte false și apare fenomenul de “alert fatigue” care este starea de epuizare mentală și profesională care apare atunci când angajații sau sistemele sunt copleșiți de un număr uriaș de notificări și alerte, devenind insensibili la acestea și ignorând sau ratând avertismentele critice.

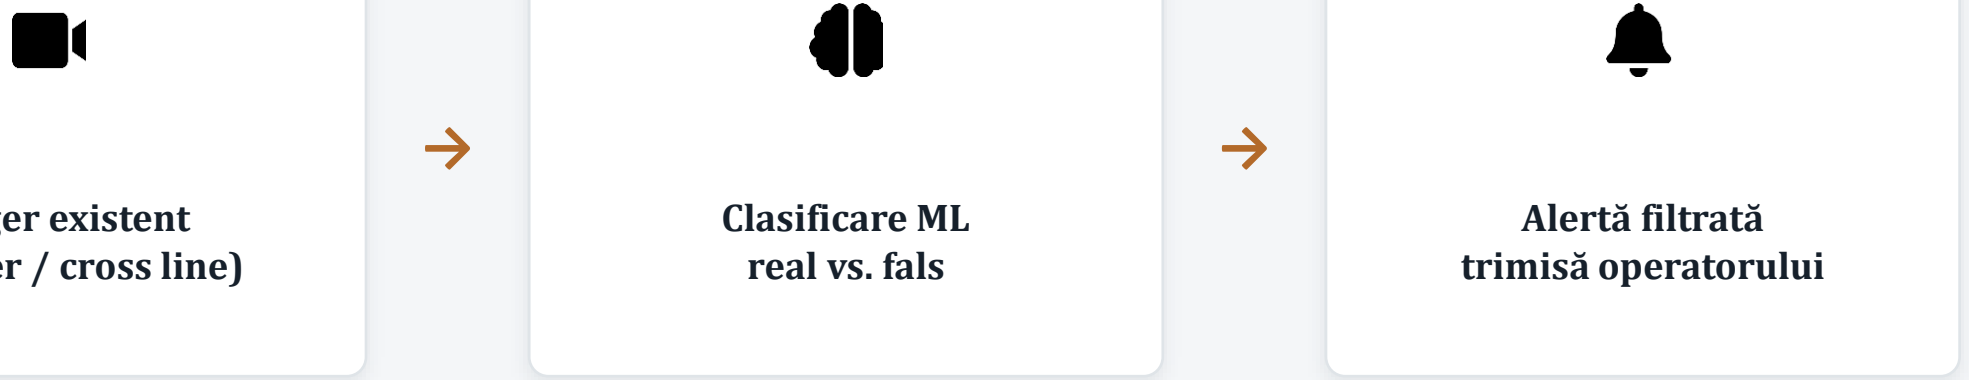
CE DECLANȘEAZĂ ALERTELE FALSE

- **Păianjeni / insecte pe lentilă**
- **Persoane ce trec prin cadrul camerei**
- **Schimbări bruște de lumină**
- **Frunze sau mișcări ale vantului**

IDEEA CENTRALĂ

Un filtru inteligent, nu un sistem nou

Peste sistemul de detecție existent (nemodificat) se adaugă un pas suplimentar: un clasificator ML care decide, pentru fiecare alertă declanșată, dacă e reală sau falsă, înainte ca alerta să ajungă la operator.



ÎNCADRAREA PRINCIPALĂ

„Alert fatigue” nu e un inconvenient operațional - e o vulnerabilitate de securitate.

Conceptul vine direct din operațiuni de securitate (SOC / IDS): când un operator primește prea multe alerte false, atenția scade și o alertă reală riscă să fie tratată la fel de superficial.

Există și un unghi de amenințare: cineva poate declanșa deliberat alarme false, repetat, ca să desensibilizeze operatorii înainte de o intruziune reală („cry wolf”).

Mă gandeam sa încep de la aceste fenomene, să fac research la început pentru lucrare. Pot să preiau statistici făcute de alții și să fac propriile statistici cu ajutorul alertelor de la muncă și ale colegilor

CE OFERĂ FIRMA

Acces real, dar date brute

OFERIT DE FIRMĂ

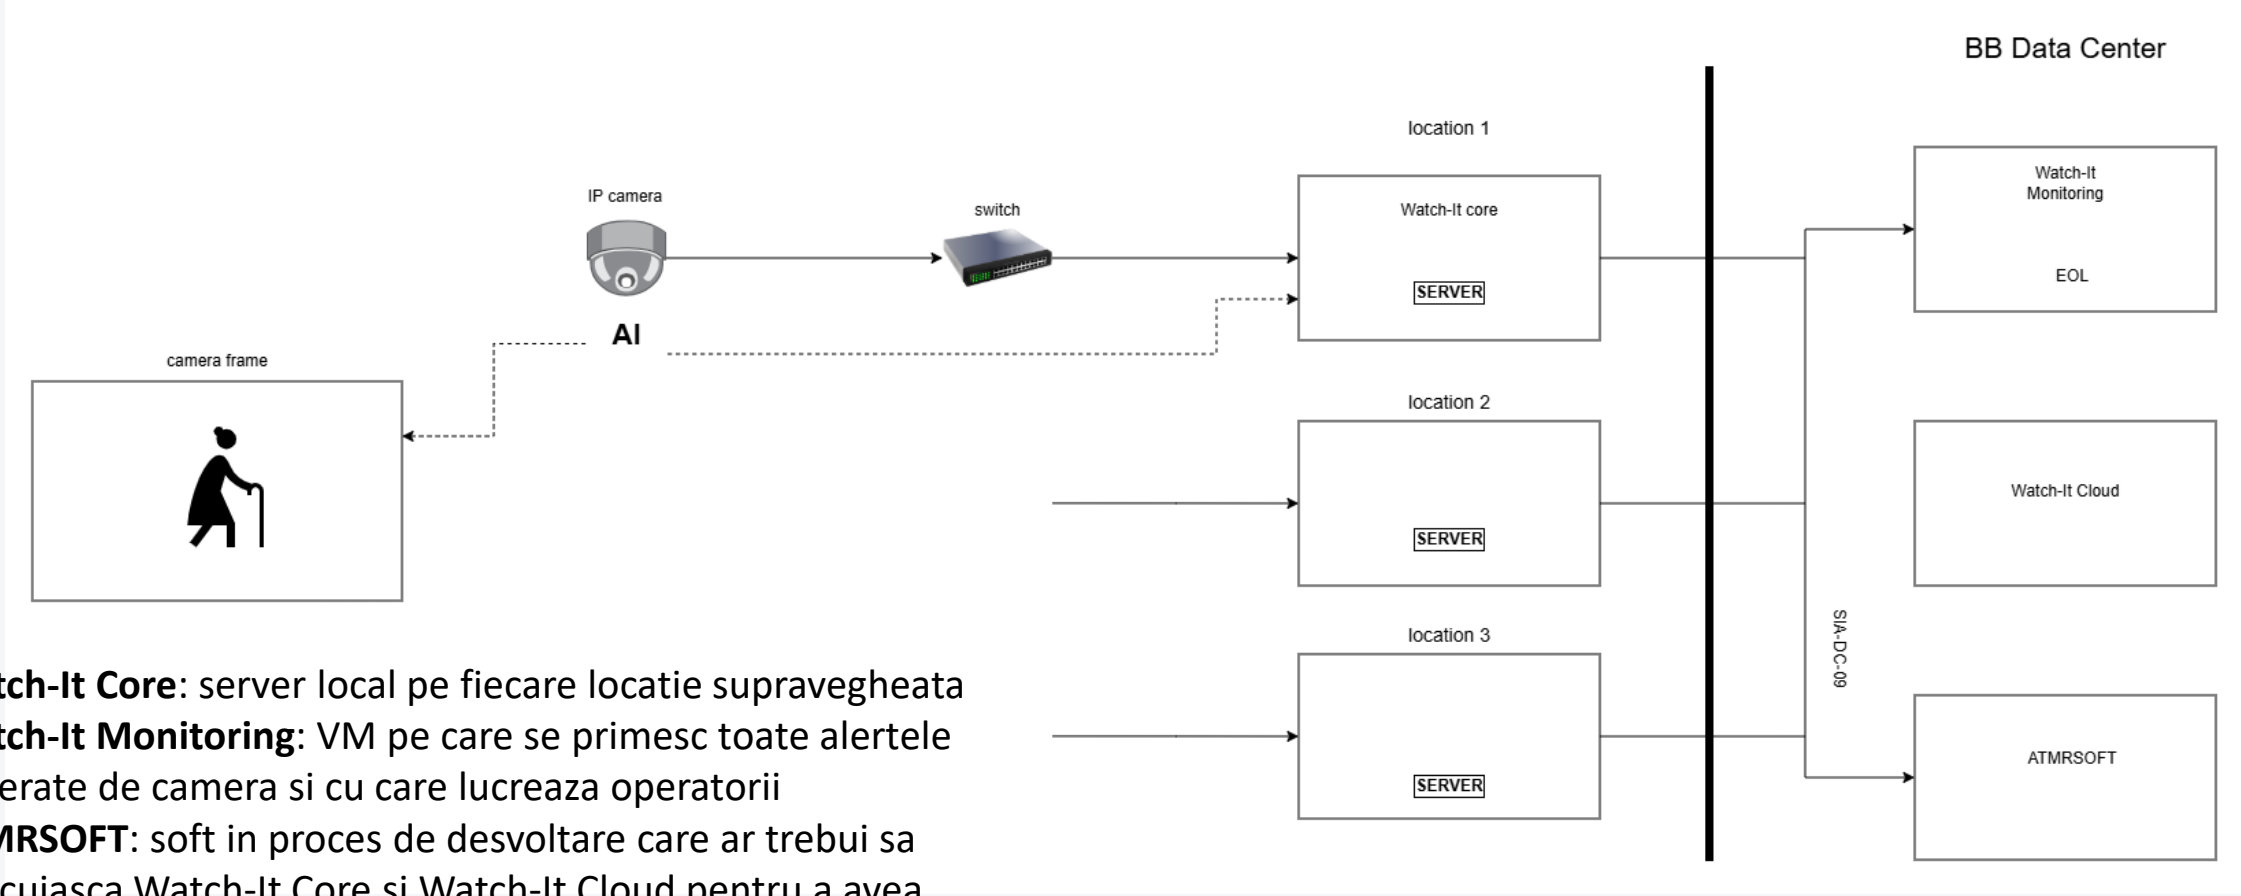
- Resurse hardware pentru antrenare/testare.
- Acces la baza de date cu istoricul alertelor.
- Videoclipuri reale din teren, de la camerele instalate.

PROVOCAREA REALĂ

Sistemul clasifică azi doar tipul de trigger (intruder, cross line), nu și dacă alerta e reală sau falsă.

Va trebui să triez și să etichetez eu datele de antrenare, real vs. fals, pornind de la aceste înregistrări brute.

Arhitectura actuală a sistemului

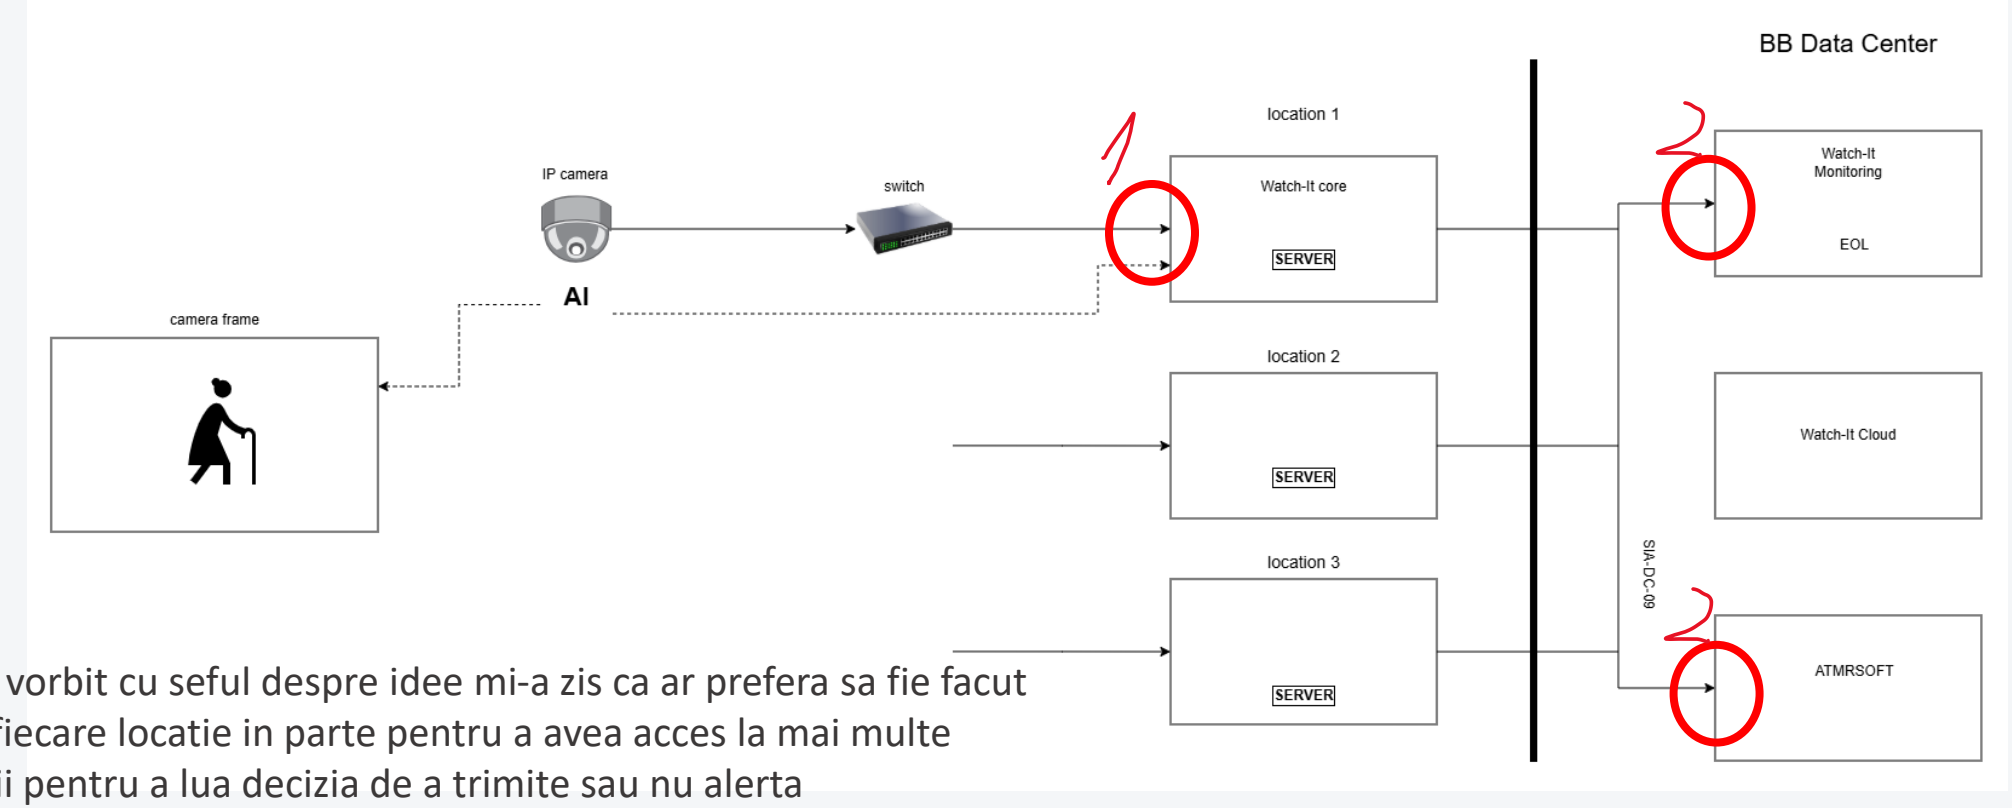


Watch-It Core: server local pe fiecare locatie supravegheata
Watch-It Monitoring: VM pe care se primesc toate alertele generate de camera si cu care lucreaza operatorii
ATMRSOFT: soft in proces de desvoltare care ar trebui sa inlocuiasca Watch-It Core si Watch-It Cloud pentru a avea totul intr-un singur loc

Ce m-am gândit eu

1. **Să pun un model de AI local pe hardware-ul disponibil pe fiecare locaţie care să facă o a doua verificare a imaginilor inainte ca alerta să fie trimisă operatorului (aș avea acces la mai multe date locale pentru a face verificările)**

1. **Să pun un singur model AI local legat la data center care sa preia alertele ce vin de pe locatii și să facă a doua verificare înainte ca alerta să fie trimisă operatorului (ar fi un singur model care face toată treaba si ar putea fi mai complex neexistând limitări hardware)**



Când am vorbit cu seful despre idee mi-a zis ca ar prefera sa fie facut totul pe fiecare locatie in parte pentru a avea acces la mai multe informatii pentru a lua decizia de a trimite sau nu alerta

IDEI DE IMPLEMENTARE

Cum filtrez zgomotul

Filtrare în cascadă

Clasificatorul ML rulează doar pe cadrele deja semnalate de trigger-ul existent, nu pe tot fluxul video.

Consistență temporală

Un obiect trebuie să persiste câteva cadre consecutive, nu doar un singur „flash”, elimină multe artefacte punctuale.

Filtre de mărime și mișcare

Resping obiecte prea mici sau prea aproape de lentilă, exact profilul unui păianjen sau al unei insecte.

Preprocesare invariantă la lumină

Normalizare de contrast/expunere înainte de clasificare, ca să reducă alertele declanșate de schimbări bruște de lumină.

TOOL-URI UTILE

De la etichetare la implementare

Etichetare date

Roboflow, CVAT sau Label Studio - pentru a marca alertele reale vs. false pe seturile primite de la firmă.

Antrenare model

PyTorch + Ultralytics YOLO (nano) sau torchvision (MobileNetV3), prin fine-tuning, nu de la zero.

Pre-filtrare clasică

OpenCV - background subtraction (MOG2/KNN) ca prim filtru ieftin, înainte de model.

Rulare locală

Export ONNX + ONNX Runtime - modelul rulează pe hardware-ul firmei, fără cloud.

Cybersecurity

SURVEY 2026

AI-Driven Security Alert Screening and Alert Fatigue Mitigation in SOCs

Sinteză recentă a metodelor asistate de AI pentru reducerea oboselii operatorilor în centre de securitate.

arxiv.org/html/2605.08316v1

ARTICOL

Combating Alert Fatigue with AlertPro

Prioritizare de alerte prin reinforcement learning, pentru atacuri multi-etapă — idee aplicabilă și la triaj video.

sciencedirect.com — S0167404823004935

ARTICOL

Using Adaptive Alert Classification to Reduce False Positives in Intrusion Detection

Clasificare adaptivă a alertelor pentru reducerea falselor pozitive în IDS — metodologie transferabilă la alerte video.

researchgate.net/publication/221427422

RESURSE DE CERCETARE · 2/4

Video analytics & detecție de intruziune

SURVEY

Perimeter Intrusion Detection by Video Surveillance: A Survey

Survey amplu, exact pe tipul de alertă cu care lucrezi (perimetru/cross line) — punct de plecare foarte bun pentru capitolul de literatură.

PMC9104546 · pmc.ncbi.nlm.nih.gov

PAPER

Reducing False Alarms in Video Surveillance by Deep Feature Statistical Modeling

Metodă de reducere a alarmelor false prin modelare statistică a trăsăturilor învățate (deep features).

arxiv.org/abs/2307.04159

REVIEW 2024

Advancing Video Anomaly Detection: A Concise Review and a New Dataset

Review recent (NeurIPS 2024) al domeniului de detecție a anomaliilor video, plus un dataset nou.

arxiv.org/html/2402.04857

RESURSE DE CERCETARE · 3/4

Seturi de date pentru antrenare și evaluare

DATASET

UCF-Crime — Real-world Anomaly Detection in Surveillance Videos

Unul din cele mai folosite seturi de date pentru anomalii în supraveghere video reală, cu cod însoțitor pe GitHub.

crcv.ucf.edu/projects/real-world

DATASET

ShanghaiTech Campus Dataset

Set de date consacrat pentru detecția de anomalii în video de campus/exterior, scenarii apropiate de supraveghere reală.

svip-lab.github.io/dataset/campus_dataset.html

Benchmark istoric & resurse vii

BENCHMARK ISTORIC

i-LIDS (Imagery Library for Intelligent Detection Systems)

Benchmark clasic pentru „sterile zone” / detecție de intruziune, citat des în literatură. Nu mai e distribuit direct din 2014 — util ca referință, nu ca sursă de descărcat.

gov.uk/guidance/imagery-library-for-intelligent-detection-systems

INDEX VIU

awesome-video-anomaly-detection

Listă actualizată de lucrări, cod și seturi de date pe detecție de anomalii video — bun punct de pornire pentru research continuu.

github.com/fjchange/awesome-video-anomaly-detection

CE MAI CONTEAZĂ

Considerații etice și practice

- Sefu vrea un acord scris cu firma, care clarifică acces, confidențialitate și ce poate apărea în lucrarea publică.
- Sin discuțiile pe care le-am avut cu șeful despre subiect a zis că dacă iese proiectul e suficient de bun poate ajunge chiar și în producție
- Se pot organiza întâlniri fizice la biroul din Cluj pentru a discuta oricând mai multe detalii

PAȘI URMĂTORI

Ce aș vrea să discutăm

01

Validarea scopului

Dacă încadrarea de cybersecurity (alert fatigue) și ideea propusa sunt suficiente pentru lucrarea de licență.

02

Alte resurse si idei

Dacă aveți de adăugat ceva în afara a ce am menționat până acum și dacă mă puteți ghida

03

Un prim calendar

Puncte de control (literatură, date, prototip) adaptate programului meu de lucru.